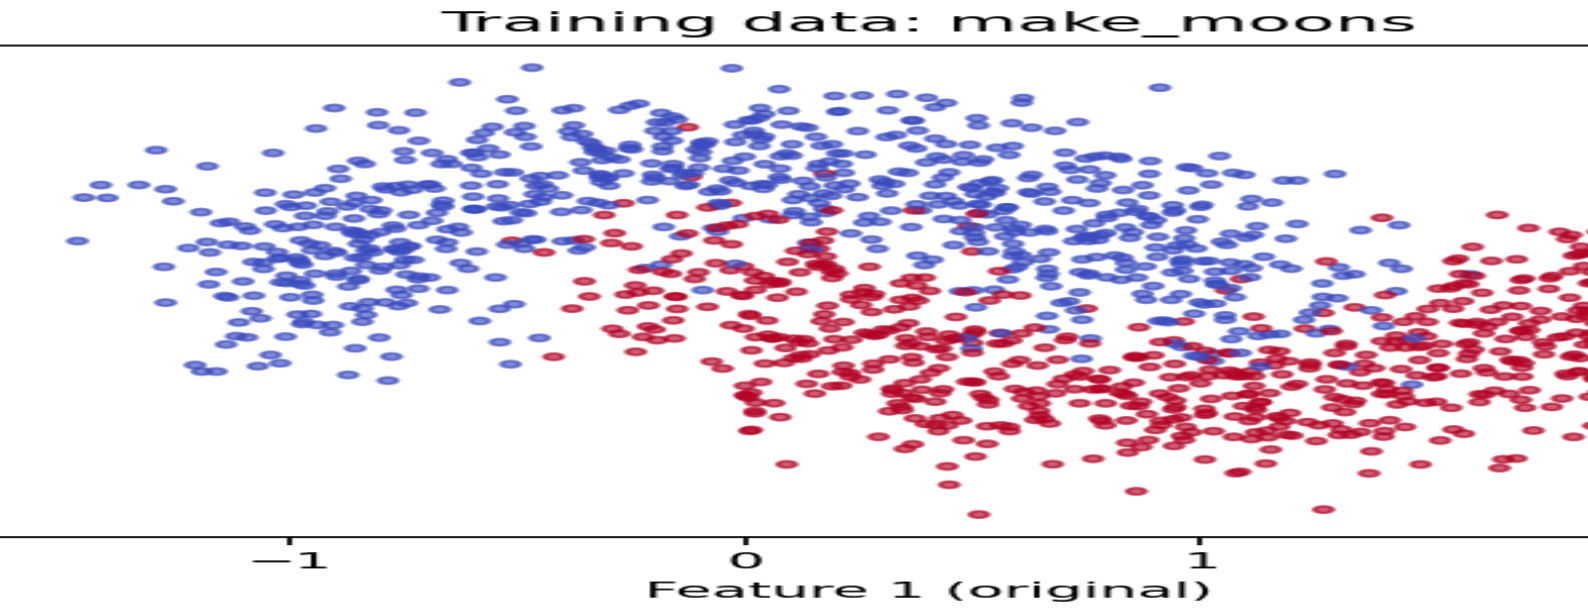
Диагностика обучения MLP

1. Выборки и подготовка

Выборка	Объектов	Класс 0	Класс 1
train	1440	720	720
validation	480	240	240
test	480	240	240

Данные: make_moons(n_samples=2400, noise=0.25, random_state=2026). Два стратифицированных разбиения с random_state=2026 и test_size 0.2, затем 0.25. Все эксперименты используют одни и те же выборки. StandardScaler обучен только на train: использование validation или test при подготовке передало бы сведения из оценочных выборок в модель.

После масштабирования train: средние признаков -0.0000, 0.0000; стандартные отклонения (ddof=0) 1.0000, 1.0000.



2. Модель, самопроверка и цикл обучения

Архитектура: $h_0 = x$; $z_l = W_l h_{l-1} + b_l$, $h_l = \varphi(z_l)$, $l = 1,\ldots,L$; выход — два линейных логита. L=1 или 6, ширина каждого скрытого слоя 32. Активации Sigmoid, Tanh и ReLU реализованы через torch.nn. Во всех скрытых слоях запуска используется одна активация.

Число параметров: первый Linear 2×32+32=96, каждый следующий 32×32+32=1056, выход 32×2+2=66. Для L=1 итог 162, для L=6 — 5442; значения сверены с sum(p.numel()). На батче из 8 объектов формы входа и выхода (8,2), loss — скаляр. После backward градиенты всех скрытых весов существуют, совпадают с ними по форме и конечны.

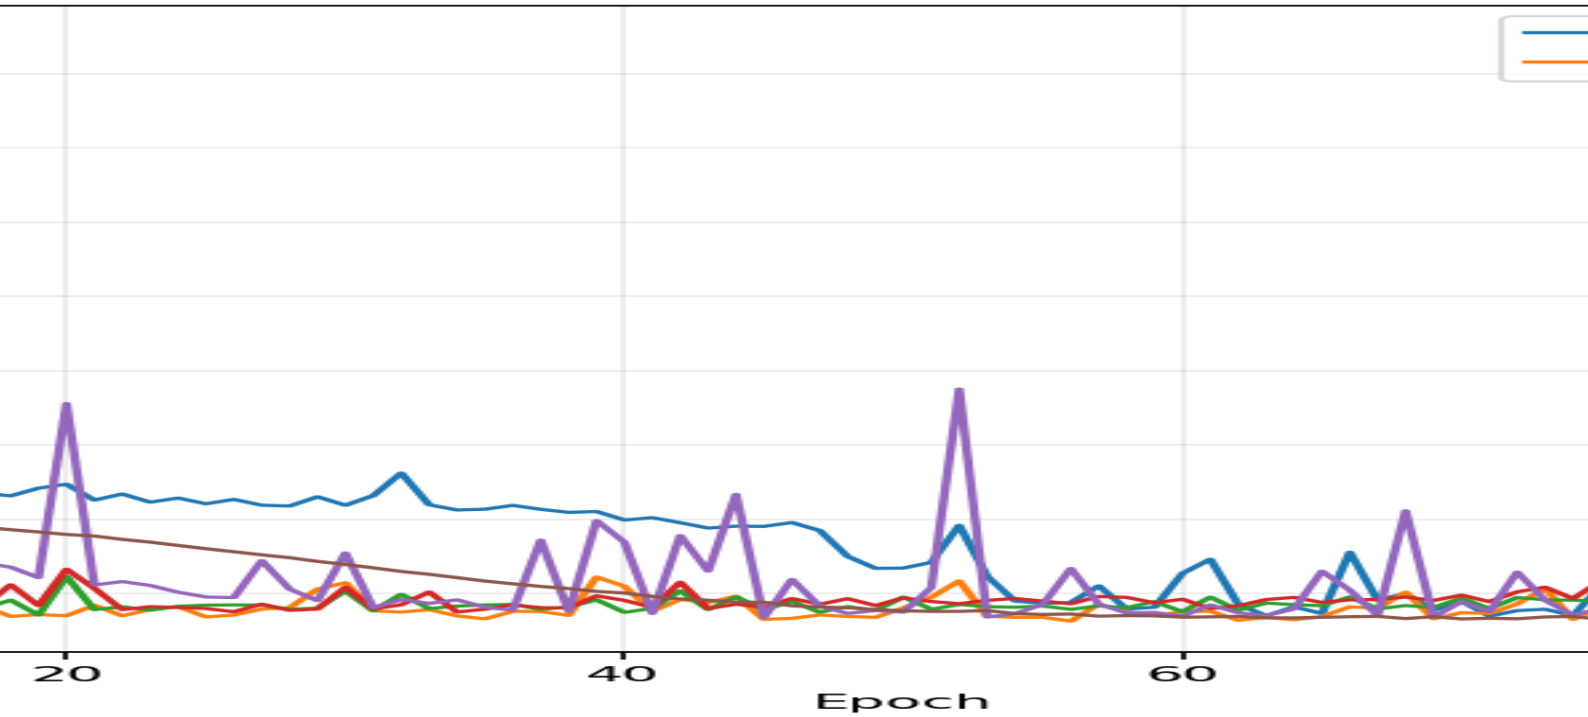
CrossEntropyLoss(reduction="mean") применяется к логитам и меткам; accuracy — доля верных argmax. Скрытые веса инициализированы Xavier normal (gain=1.0) или He normal (fan_in, relu), выходные — Xavier normal, все смещения нулевые. Перед каждым запуском задан torch.manual_seed(seed), отдельный Generator для DataLoader получает 10000+seed. За 100 эпох обучающие объекты перемешиваются, batch size 128. Шаг: zero_grad → forward → loss → backward → step. Метрики на полных train и validation записываются до обучения и после каждой эпохи в eval/no_grad; перед следующей эпохой включается train. Расчёт выполнен на CPU с torch.set_num_threads(1).

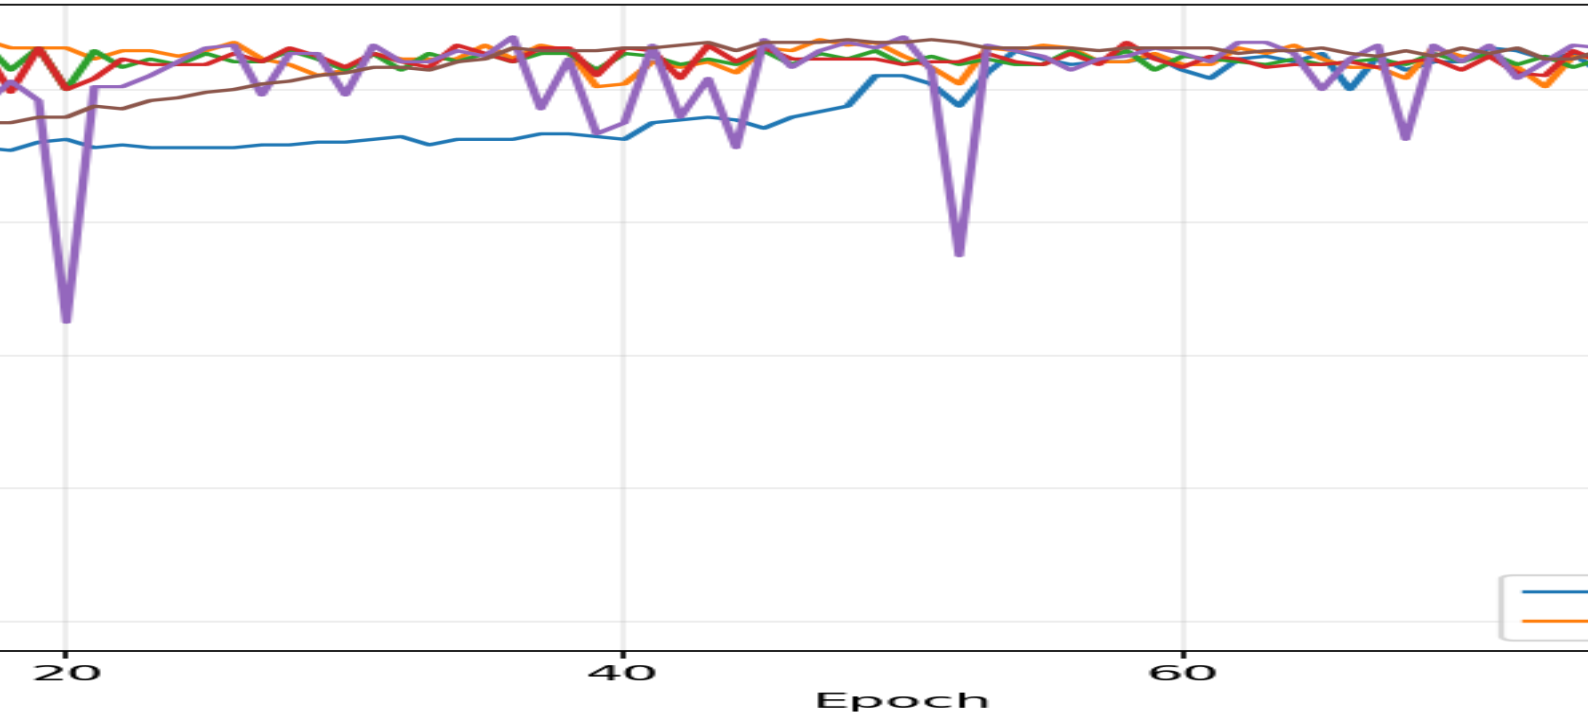
3. Эксперименты и сравнения

Код	Слои	Активация	Начальные веса	Оптимизатор	LR
A	6	Sigmoid	Xavier	Adam	0.003
B	6	Tanh	Xavier	Adam	0.003
C	6	ReLU	Xavier	Adam	0.003
D	6	ReLU	He	Adam	0.003
E	6	ReLU	He	SGD	0.05
F	1	ReLU	He	Adam	0.003

Код	Seed	Train loss	Train acc	Val loss	Val acc
A	11	0.1465	0.9472	0.1863	0.9187
A	29	0.1444	0.9438	0.1787	0.9187
B	11	0.1347	0.9479	0.1874	0.9125
B	29	0.1345	0.9465	0.1714	0.9208
C	11	0.1164	0.9507	0.1985	0.9229
C	29	0.1253	0.9444	0.2085	0.9167
D	11	0.1054	0.9556	0.2004	0.9229
D	29	0.1135	0.9569	0.2340	0.9125
E	11	0.1949	0.9187	0.2640	0.8917
E	29	0.2393	0.8986	0.2995	0.8708
F	11	0.1380	0.9458	0.1662	0.9250
F	29	0.1360	0.9472	0.1685	0.9229

Код	Средний val loss двух seed, эпоха 100
A	0.1825
B	0.1794
C	0.2035
D	0.2172
E	0.2818
F	0.1674





A/B/C при Xavier: на эпохе 0 val loss для seed 11 — 0.6959/0.5140/0.6841, на эпохе 20 — 0.3469/0.1699/0.2229, на эпохе 100 — 0.1863/0.1874/0.1985. Sigmoid снижается медленнее в начале, что согласуется с ослаблением градиента к ранним слоям. Tanh быстро снижает loss, но при seed 11 к концу слегка ухудшается относительно эпохи 20; общее превосходство одной активации по двум seed утверждать нельзя.

C→D изолирует масштаб инициализации при ReLU. На эпохе 0 val loss C/D равен 0.6841/0.5655 при seed 11. Не даёт гораздо более крупные начальные нормы градиентов, но финальный val loss D не ниже C: 0.2004 против 0.1985; при seed 29 — 0.2340 против 0.2085. Начальный масштаб сам по себе не гарантирует лучшее обобщение.

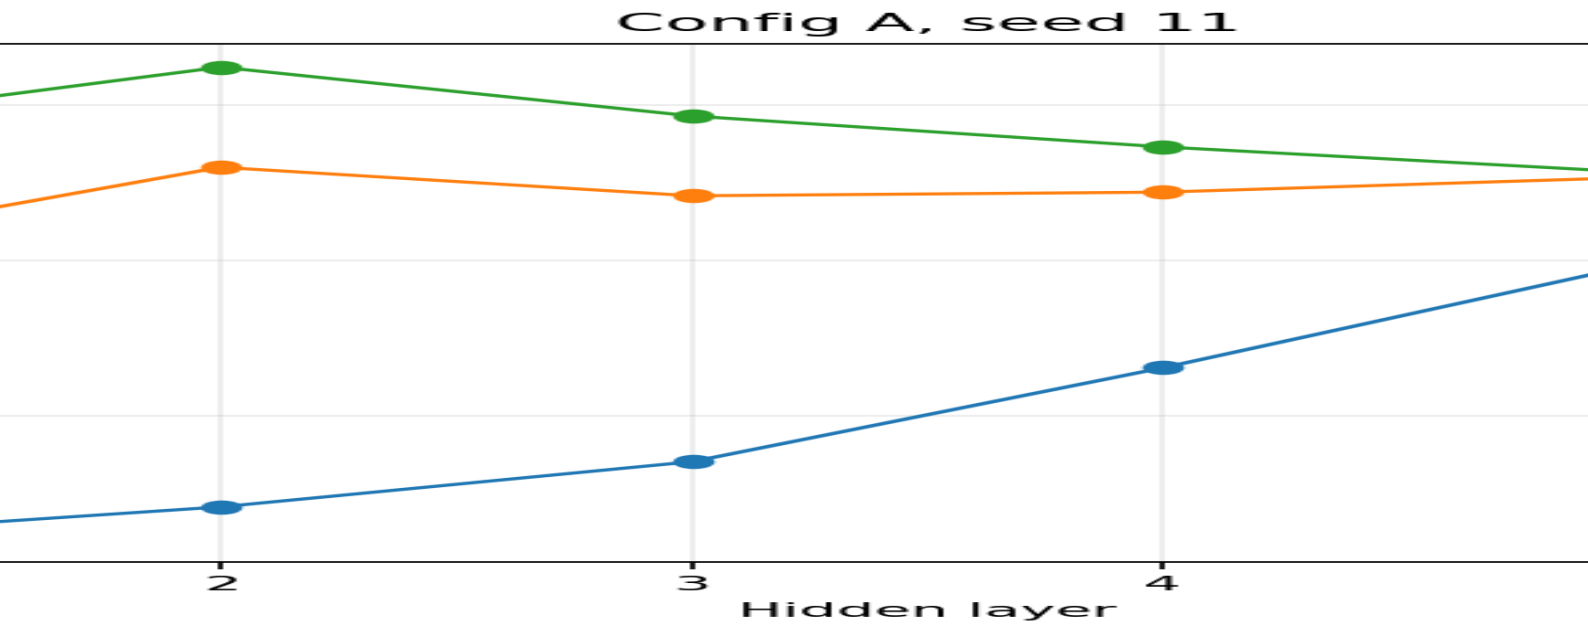
D/E стартуют с одинаковых весов при каждом seed, поэтому epoch 0 совпадает. При seed 11 к эпохе 20 val loss D/E равен 0.2325/0.4556, к эпохе 100 — 0.2004/0.2640. При seed 29 итог 0.2340/0.2995. В заданных

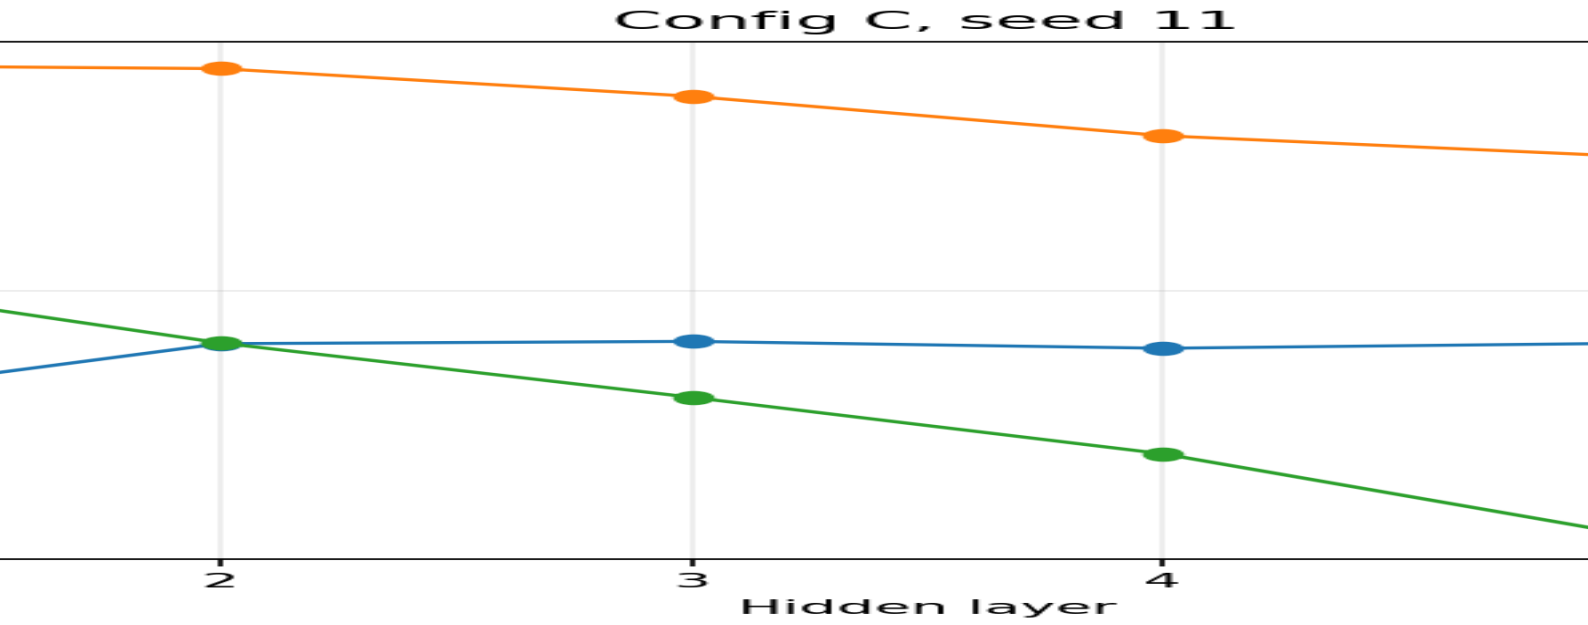
режимах Adam 0.003 снижает loss быстрее и достигает лучшей оценки, но отдельно эффект оптимизатора оценить нельзя: learning rate также разный.

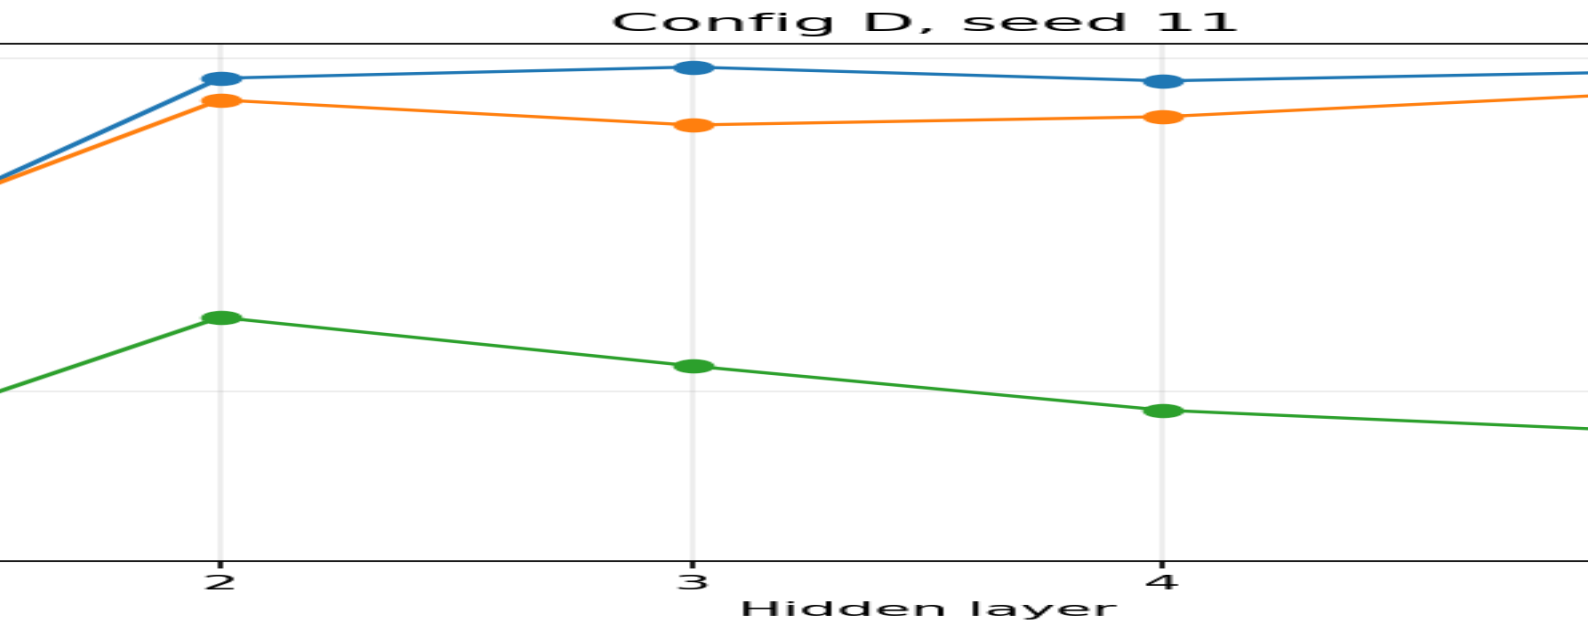
D/F: при seed 11 итоговый val loss 6-слойной/1-слойной модели 0.2004/0.1662, при seed 29 — 0.2340/0.1685. F имеет 162 параметра против 5442 у D и в этих запусках обобщает лучше. Одновременно меняются глубина и число параметров, поэтому вклад каждого фактора отдельно неизвестен. На seed 29 качественная картина D/E и D/F повторяется, а порядок A/B/C зависит от seed. Фиксированные learning rate и всего два seed ограничивают выводы.

4. Диагностика градиентов

На фиксированных первых 128 объектах train после масштабирования вычислена $g_l(t)=\|\partial CE(f_{\theta_t}(X_{probe}),y_{probe})/\partial W_l\|_F$. Для A, C, D с seed 11 и 29 на эпохах 0, 20 и 100 выполнены отдельные forward/backward без обновления параметров. Полные значения всех слоёв сохранены в results/gradients.csv; нулевых и нечисловых норм нет.







Код	Seed	Эпоха	Слой 1	Слой 6
A	11	0	0.0002	0.0391
A	11	20	0.0114	0.0460
A	11	100	0.0713	0.0281
A	29	0	0.0002	0.0327
A	29	20	0.0098	0.0373
A	29	100	0.0692	0.0121
C	11	0	0.0432	0.0802
C	11	20	0.5243	0.2347
C	11	100	0.1132	0.0190
C	29	0	0.0964	0.0449
C	29	20	0.1807	0.0270
C	29	100	0.2812	0.0228
D	11	0	0.1979	0.9080
D	11	20	0.2210	0.5768
D	11	100	0.0558	0.0364
D	29	0	0.6163	1.9978
D	29	20	0.1095	0.0919
D	29	100	0.0887	0.0805

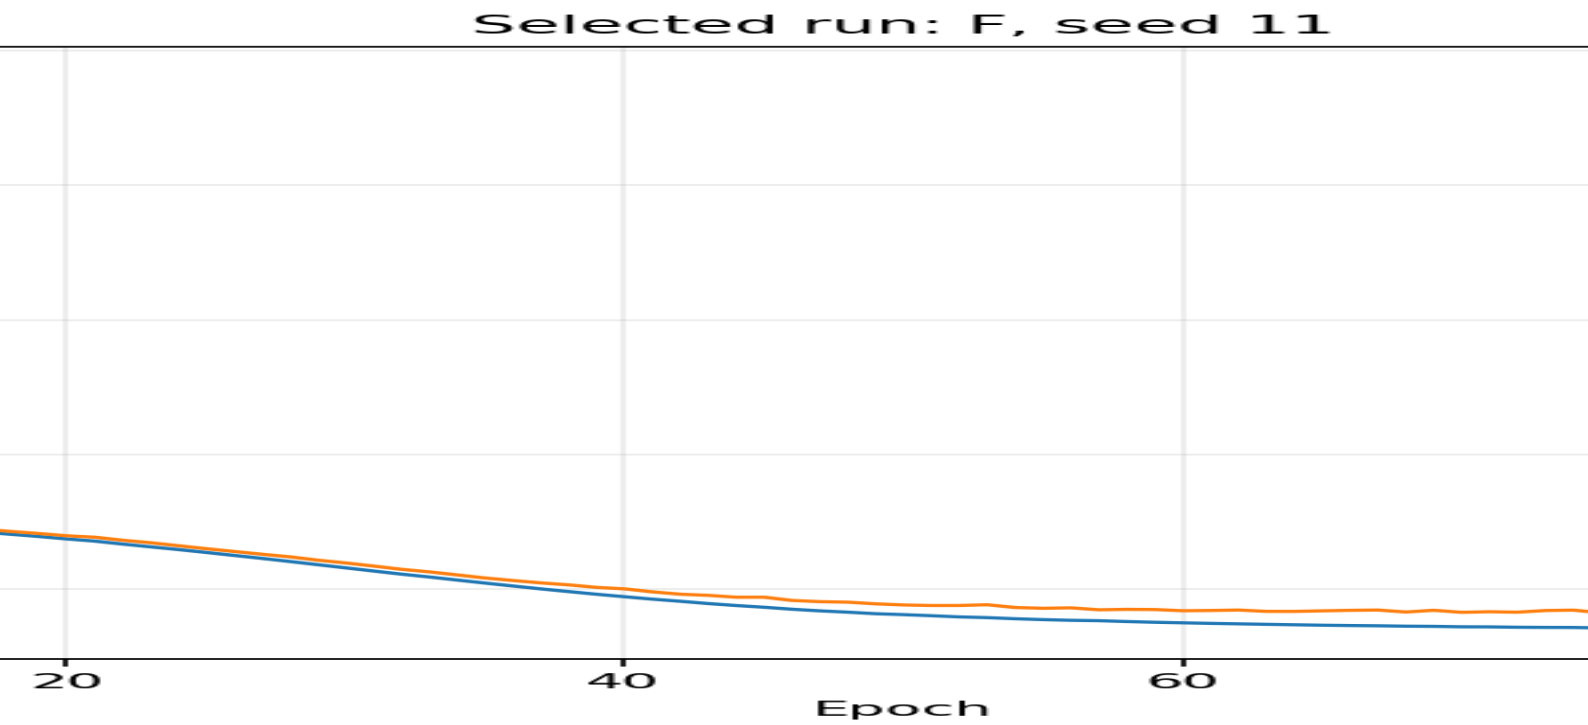
У Sigmoid производная не больше 1/4; при обратном проходе через шесть слоёв множители правила цепочки могут уменьшить градиент ранних весов. На эпохе 0 у A норма слоя 1 для seed 11/29 — 0.0002/0.0002, а слоя 6 — 0.0391/0.0327. У C для слоя 1 соответствующие значения 0.0432/0.0964. ReLU не уменьшает сигнал множителем 1/4 на активных нейронах.

На эпохе 0 Не даёт у D нормы слоя 1 0.1979/0.6163 против 0.0432/0.0964 у C; на эпохе 100 порядок по слоям уже неодинаков: слой 1 C/D для seed 11 — 0.1132/0.0558, слой 6 — 0.0190/0.0364. Та же смена порядка наблюдается при seed 29. Норма градиента весов зависит также от входных активаций слоя и

размера матрицы; скорость снижения validation loss определяется шагами оптимизатора и поведением на другой выборке, поэтому одну норму нельзя считать мерой скорости обучения.

5. Выбор модели и обобщение

По среднему val loss двух seed на эпохе 100 выбрана F (0.1674). Внутри F меньший val loss у seed 11: 0.1662 против 0.1685. Test использован только после выбора. Для F/11 test loss=0.1302, test accuracy=0.9438.



У выбранного запуска train loss на эпохах 20/100 равен 0.2746/0.1380, validation loss — 0.2793/0.1662. Обе кривые снижаются; явного признака остановившейся оптимизации нет. Итоговая train accuracy 0.9458, validation accuracy 0.9250, test accuracy 0.9438. Validation loss выше train loss на 0.0283, test loss ниже validation loss на 0.0360. Одна test оценка не показывает разброс качества на других выборках.

Три вывода: (1) При Xavier активация влияет на ранний ход обучения: к эпохе 20 val loss A/B/C при seed 11 равен 0.3469/0.1699/0.2229; малая начальная норма раннего градиента A согласуется с ослаблением через производные Sigmoid. (2) Не увеличивает начальный масштаб градиентов ReLU: слой 1 C/D при seed 11 0.0432/0.1979, но к эпохе 100 val loss C/D 0.1985/0.2004; большая норма не означает лучшее обобщение. (3) Для заданных режимов D/E разница в темпе видна уже на эпохе 20: 0.2325/0.4556, и сохраняется к эпохе 100: 0.2004/0.2640. Она связана с совокупностью алгоритма обновления и learning rate.

Недостаточно данных для вывода «Adam вообще лучше SGD»: в D/E меняются одновременно оптимизатор и шаг, а каждый вариант проверен лишь на двух seed.

6. Воспроизводимость

main.py воспроизводит 12 запусков, результаты в results/, выбор модели, оценку test, сравнительную таблицу final_comparison.csv и обязательные графики в figures/. report.pdf — готовый отчёт; main.py не создаёт его заново. Команды установки и запуска, конфигурации и устройство приведены в README.md. Версии библиотек закреплены в requirements.txt.