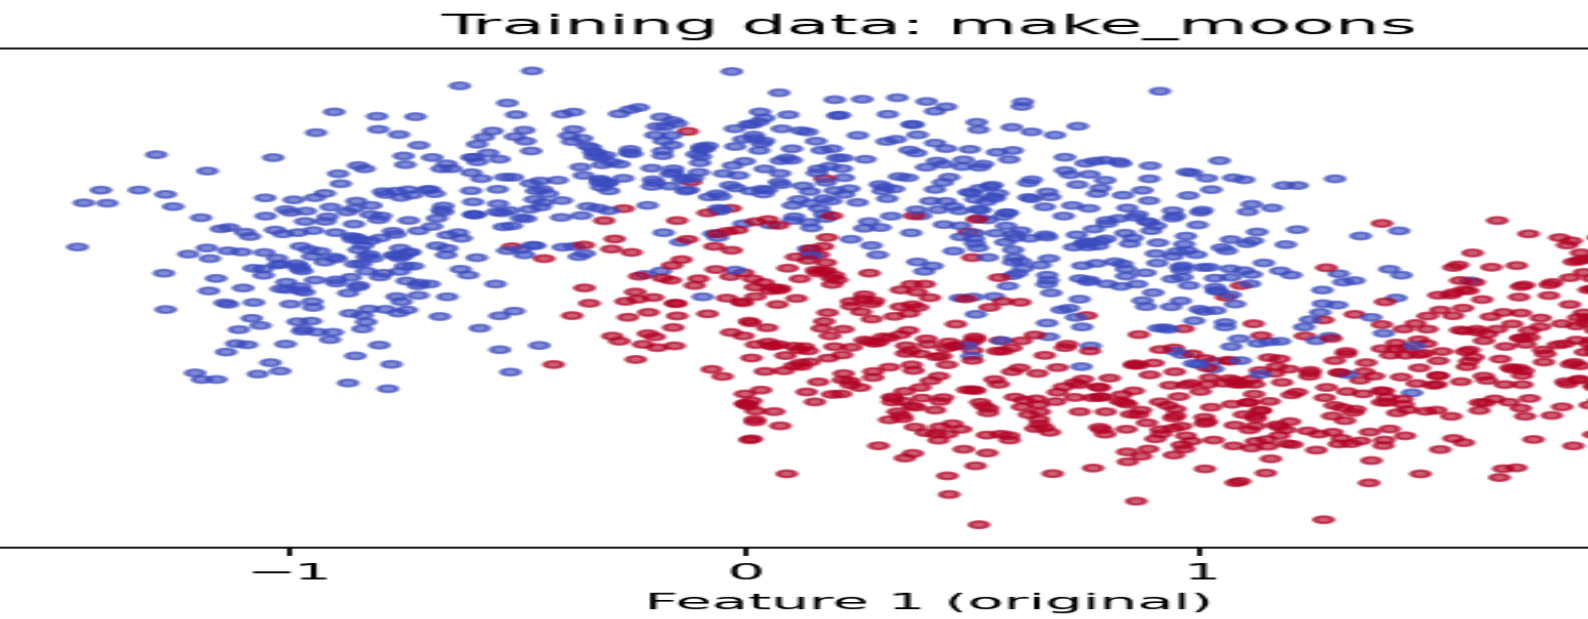
Лабораторная работа: диагностика обучения MLP

1. Данные и подготовка

Выборка	Объектов	Класс 0	Класс 1
train	1440	720	720
validation	480	240	240
test	480	240	240

Данные make_moons: 2400 объектов, noise=0.25, random_state=2026. Два стратифицированных разбиения с random_state=2026 дают train/validation/test = 1440/480/480. StandardScaler обучен только на train: обучение на других выборках передало бы информацию из оценки в процедуру подготовки.

После масштабирования train: средние признаков -0.0000, 0.0000; стандартные отклонения (ddof=0) 1.0000, 1.0000.



2. Модель и обучение

MLP принимает два признака, содержит 1 или 6 полносвязных скрытых слоёв ширины 32 и линейный выход из двух логитов. Во всех скрытых слоях запуска используется одна активация. CrossEntropyLoss(reduction='mean') получает логиты и целочисленные метки; accuracy — доля совпадений argmax с метками.

Число параметров: первый слой 2×32+32=96; каждый последующий 32×32+32=1056; выход 32×2+2=66. Итого для 1 слоя 162, для 6 слоёв 5442. Проверка через sum(p.numel()) дала те же числа. На батче из 8 объектов формы входа и выхода (8, 2), loss — скаляр; градиенты весов всех скрытых слоёв присутствуют, совпадают по форме с весами и конечны.

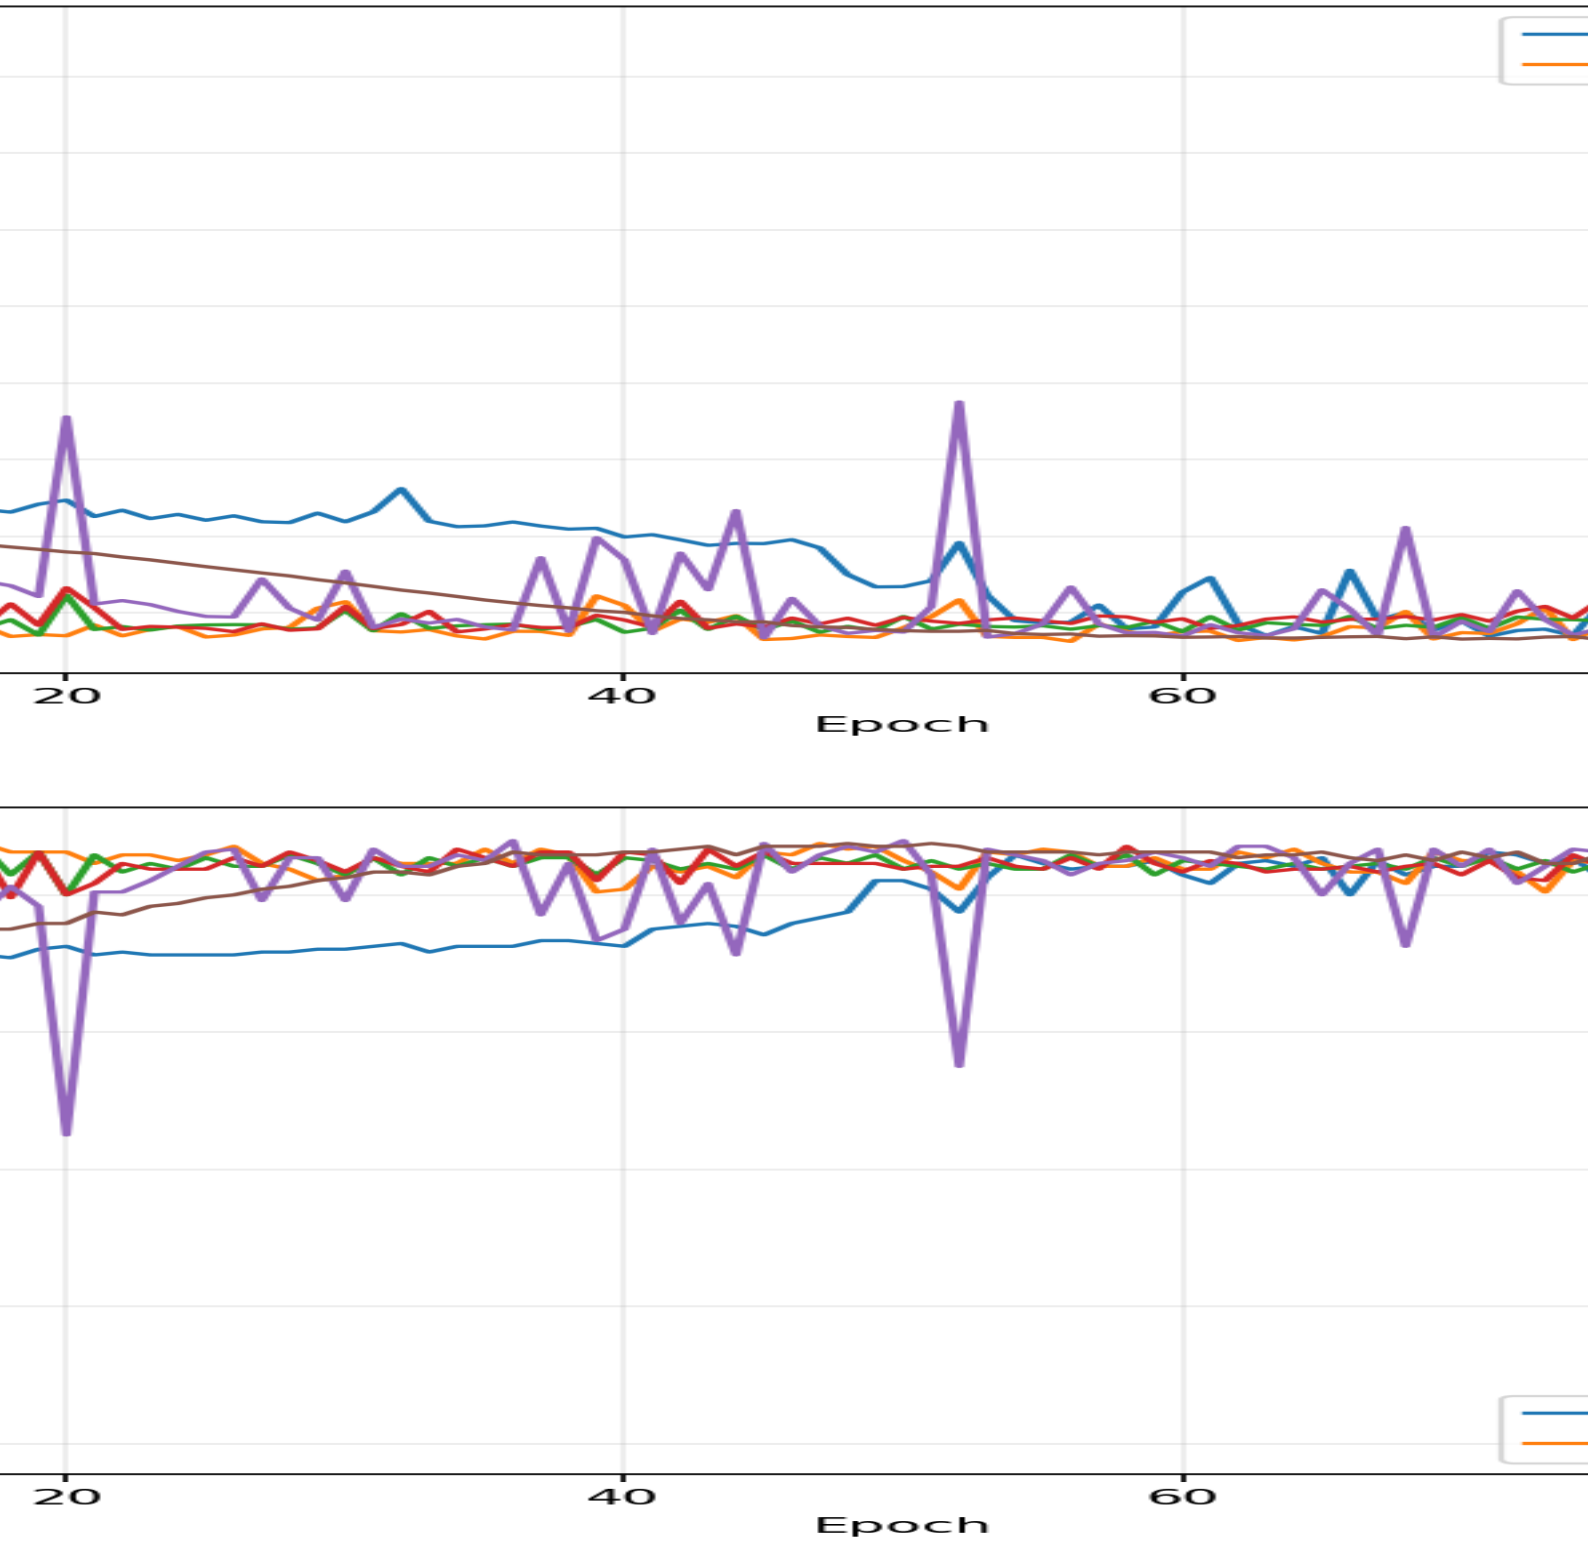
Каждый запуск начинается с torch.manual_seed(seed). DataLoader получает отдельный Generator с seed 10000+seed, перемешивает train каждую эпоху, batch size 128. На каждом шаге: zero_grad → forward → loss → backward → step. Метрики вычисляются на полных train и validation до обучения и после каждой из 100 эпох в eval/no_grad. Все запуски выполнены на CPU, torch.set_num_threads(1).

3. Контролируемые эксперименты

Код	Слои	Активация	Скрытые веса	Оптимизатор	LR
A	6	Sigmoid	Xavier	Adam	0.003
B	6	Tanh	Xavier	Adam	0.003
C	6	ReLU	Xavier	Adam	0.003
D	6	ReLU	He	Adam	0.003
E	6	ReLU	He	SGD	0.05
F	1	ReLU	He	Adam	0.003

Код	Seed	Train loss	Train acc	Val loss	Val acc
A	11	0.1465	0.9472	0.1863	0.9187
A	29	0.1444	0.9438	0.1787	0.9187
B	11	0.1347	0.9479	0.1874	0.9125
B	29	0.1345	0.9465	0.1714	0.9208
C	11	0.1164	0.9507	0.1985	0.9229
C	29	0.1253	0.9444	0.2085	0.9167
D	11	0.1054	0.9556	0.2004	0.9229
D	29	0.1135	0.9569	0.2340	0.9125
E	11	0.1949	0.9187	0.2640	0.8917
E	29	0.2393	0.8986	0.2995	0.8708
F	11	0.1380	0.9458	0.1662	0.9250
F	29	0.1360	0.9472	0.1685	0.9229

Код	Средний val loss, эпоха 100
A	0.1825
B	0.1794
C	0.2035
D	0.2172
E	0.2818
F	0.1674



Sigmoid/Tanh, seed 11: на эпохе 0 val loss A=0.6959, B=0.5140; на эпохе 20 A=0.3469, B=0.1699; на эпохе 100 A=0.1863, B=0.1874. Для seed 29 на эпохе 100: A=0.1787, B=0.1714.

Tanh/ReLU, seed 11: на эпохе 0 val loss B=0.5140, C=0.6841; на эпохе 20 B=0.1699, C=0.2229; на эпохе 100 B=0.1874, C=0.1985. Для seed 29 на эпохе 100: B=0.1714, C=0.2085.

Xavier/He, seed 11: на эпохе 0 val loss C=0.6841, D=0.5655; на эпохе 20 C=0.2229, D=0.2325; на эпохе 100 C=0.1985, D=0.2004. Для seed 29 на эпохе 100: C=0.2085, D=0.2340.

Adam 0.003/SGD 0.05, seed 11: на эпохе 0 val loss D=0.5655, E=0.5655; на эпохе 20 D=0.2325, E=0.4556; на эпохе 100 D=0.2004, E=0.2640. Для seed 29 на эпохе 100: D=0.2340, E=0.2995.

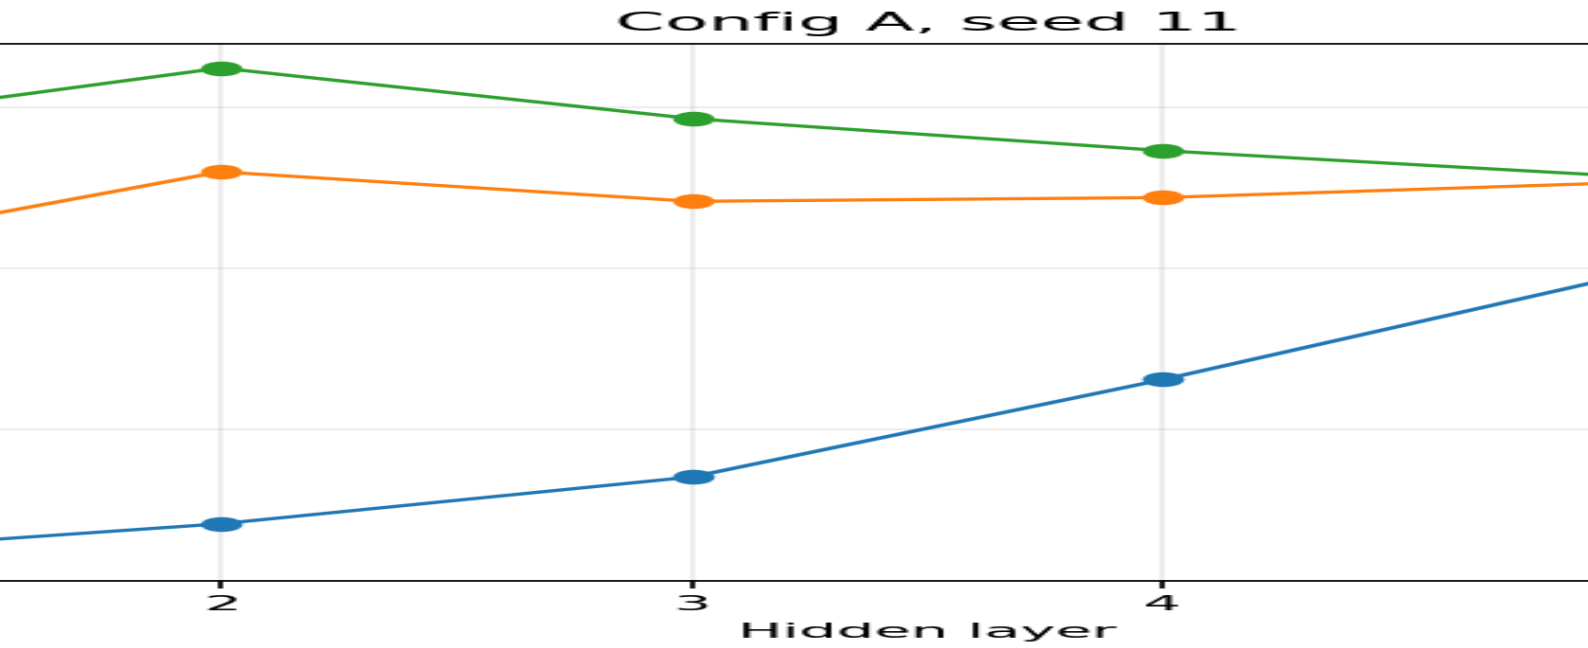
6 слоёв/1 слой, seed 11: на эпохе 0 val loss D=0.5655, F=0.9517; на эпохе 20 D=0.2325, F=0.2793; на эпохе 100 D=0.2004, F=0.1662. Для seed 29 на эпохе 100: D=0.2340, F=0.1685.

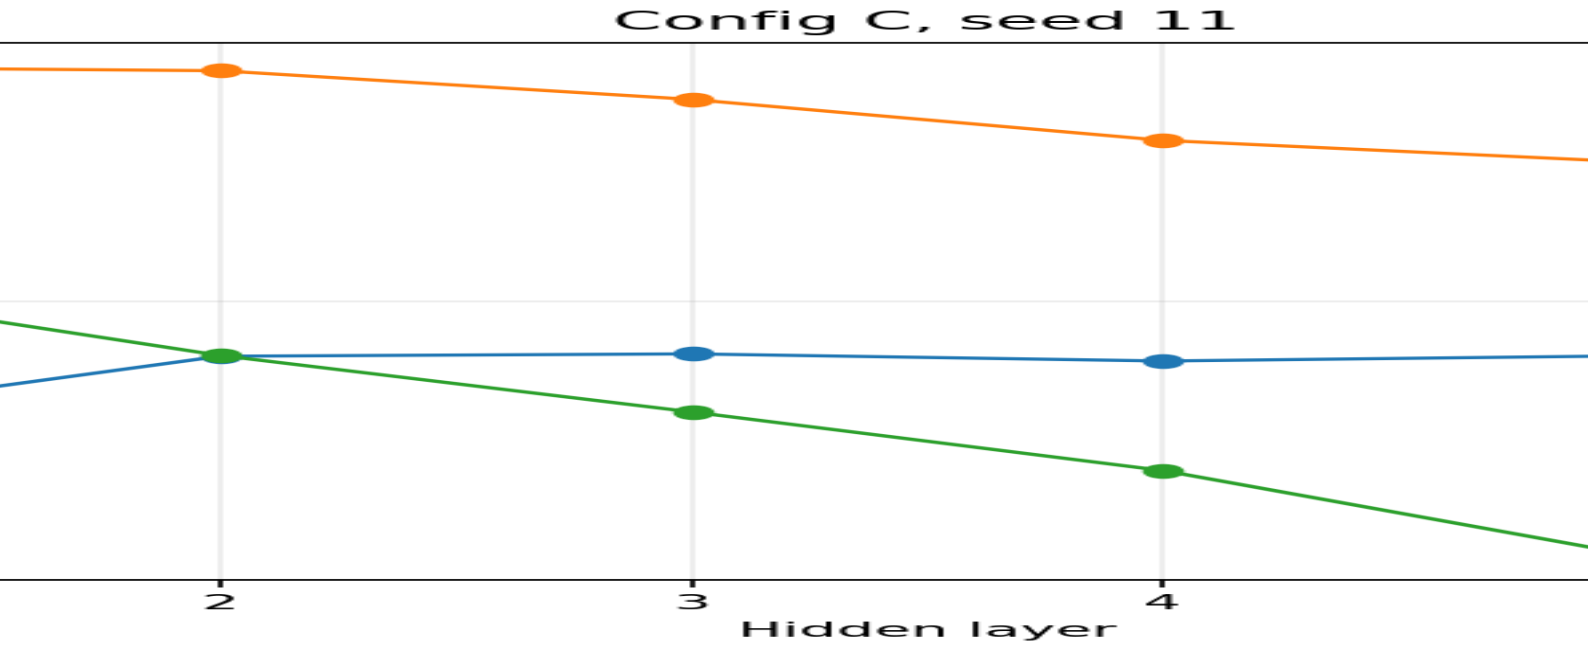
Сравнение A–C относится к Xavier normal с gain=1.0. В D–E одновременно меняются оптимизатор и learning rate, поэтому их эффекты по отдельности не определяются. В D–F меняются глубина и число параметров (5442 против 162). Два seed показывают устойчивость конкретных запусков, но недостаточны для оценки распределения результатов по инициализациям.

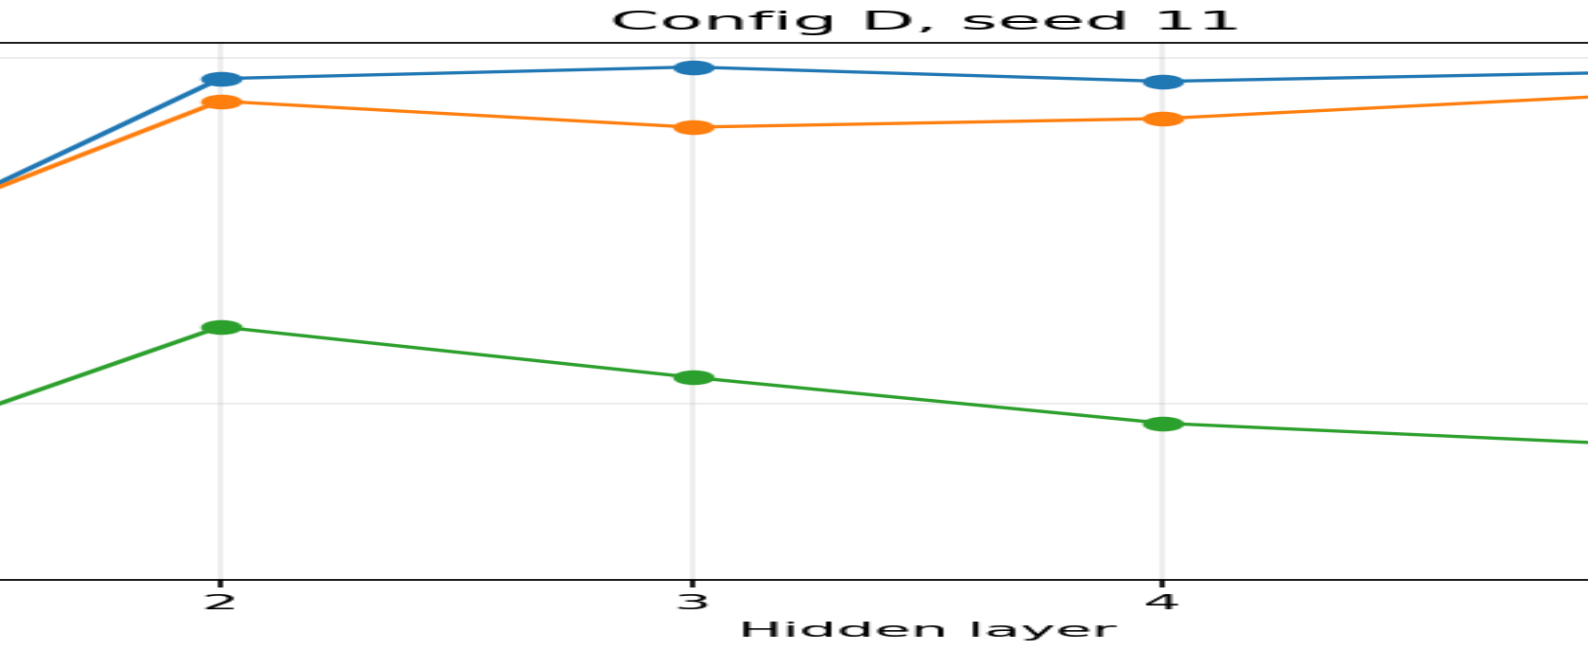
По seed 29 общая картина сохраняется: к эпохе 100 F имеет меньший val loss, чем D и E (0.1685 против 0.2340 и 0.2995); на эпохе 20 E ещё медленнее D (0.2125 против 0.1774). Порядок A/B/C по отдельным эпохам меняется между seed, поэтому преимущество одной активации в целом из этих данных не следует.

4. Градиенты скрытых слоёв

Норма Фробениуса градиента весов измерена на неизменном batch из первых 128 train объектов после масштабирования. На эпохах 0, 20 и 100 для A, C, D выполнены отдельные forward/backward без изменения параметров. Полная таблица для обоих seed находится в results/gradients.csv.







Код	Seed	Эпоха	Слой 1	Слой 6
A	11	0	0.0002	0.0391
A	11	100	0.0713	0.0281
A	29	0	0.0002	0.0327
A	29	100	0.0692	0.0121

Код	Seed	Эпоха	Слой 1	Слой 6
C	11	0	0.0432	0.0802
C	11	100	0.1132	0.0190
C	29	0	0.0964	0.0449
C	29	100	0.2812	0.0228

Код	Seed	Эпоха	Слой 1	Слой 6
D	11	0	0.1979	0.9080
D	11	100	0.0558	0.0364
D	29	0	0.6163	1.9978
D	29	100	0.0887	0.0805

Нулевых норм: нет.

У Sigmoid производная не превышает 1/4; при прохождении через шесть слоёв множители правила цепочки способны уменьшать сигнал к ранним слоям. У ReLU производная на положительных входах равна 1, поэтому начальные нормы могут вести себя иначе. Сопоставление C и D показывает влияние масштаба начальных весов при одной активации. Сама норма градиента весов не задаёт скорость снижения validation loss: она зависит от активаций на входе слоя, числа элементов матрицы и текущего состояния оптимизатора; validation loss измеряется на других объектах.

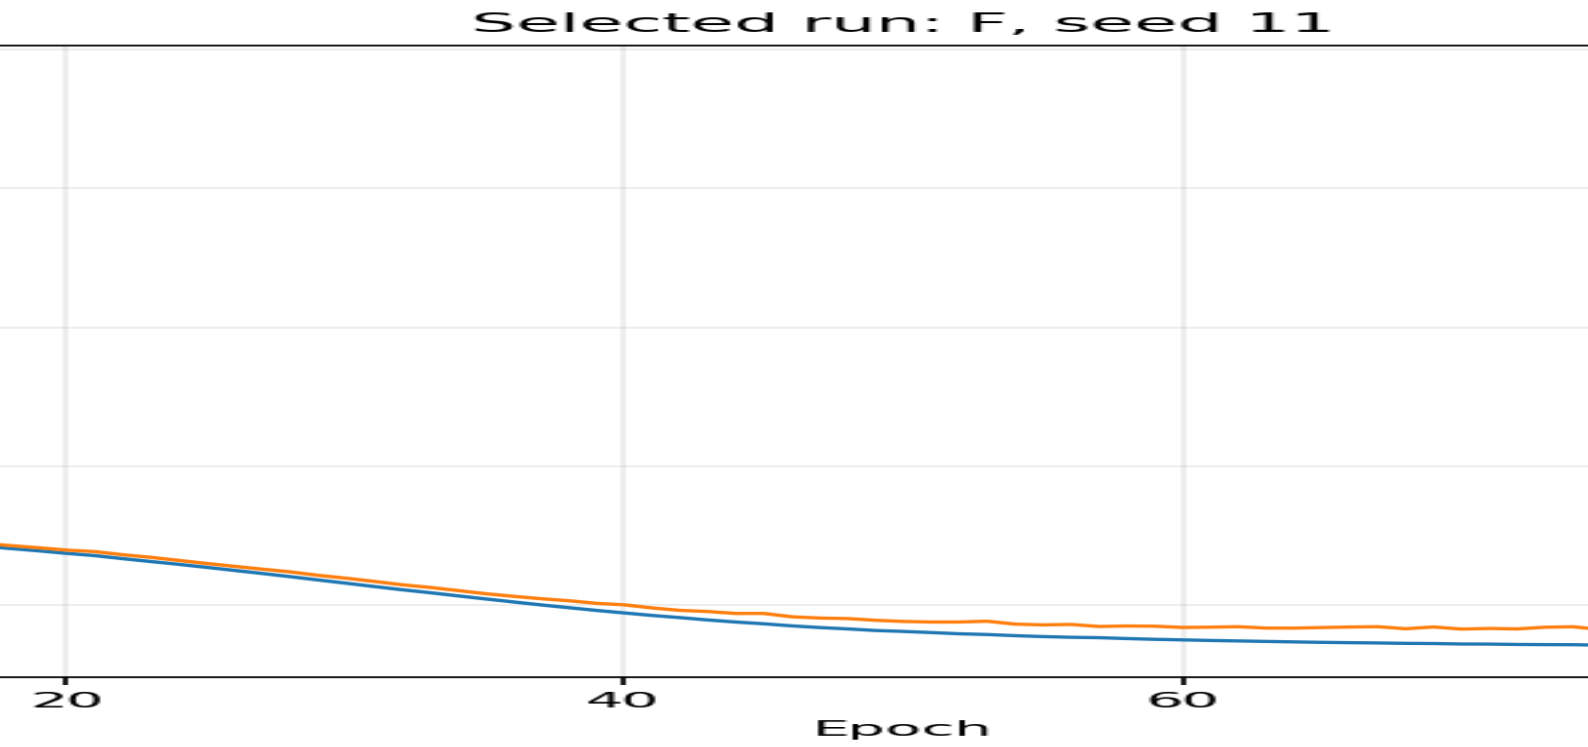
Seed 11: на эпохе 0 норма слоя 1 A/C/D = 0.0002/0.0432/0.1979; слоя 6 = 0.0391/0.0802/0.9080. На эпохе 100 C/D, слой 1 = 0.1132/0.0558; слой 6 = 0.0190/0.0364. Очень малая начальная норма раннего слоя A и больший начальный масштаб D повторяются на обоих seed; на эпохе 100 простого постоянного

превосходства D над C по всем слоям нет.

Seed 29: на эпохе 0 норма слоя 1 A/C/D = 0.0002/0.0964/0.6163; слоя 6 = 0.0327/0.0449/1.9978. На эпохе 100 C/D, слой 1 = 0.2812/0.0887; слой 6 = 0.0228/0.0805. Очень малая начальная норма раннего слоя A и больший начальный масштаб D повторяются на обоих seed; на эпохе 100 простого постоянного превосходства D над C по всем слоям нет.

5. Выбор модели и итоговая оценка

Минимальное среднее val loss на эпохе 100 — у конфигурации F: 0.1674. Внутри неё выбран seed 11, val loss 0.1662. Единственная оценка на test после выбора: loss 0.1302, accuracy 0.9438.



Для выбранного запуска train loss 0.1380, train accuracy 0.9458; validation loss 0.1662, validation accuracy 0.9250. На эпохе 20 train/validation loss 0.2746/0.2793; к эпохе 100 обе величины снизились до 0.1380/0.1662. У выбранного запуска нет признака остановившейся оптимизации: train loss продолжает снижаться. Validation loss выше train loss на 0.0283; test loss ниже validation loss на 0.0360. Один test замер не позволяет оценить разброс качества обобщения.

Вывод 1. При Xavier normal выбор активации меняет раннюю динамику: на эпохе 20 val loss A/B/C равен 0.3469/0.1699/0.2229 (seed 11).

Вывод 2. При ReLU смена Xavier на He меняет масштаб начальных сигналов и результат: val loss C/D на эпохе 100 равен 0.1985/0.2004 (seed 11).

Вывод 3. Заданные пары оптимизатора и шага дают разные траектории: val loss D/E на эпохе 100 равен 0.2004/0.2640 (seed 11).

По этим опытам нельзя утверждать, что Adam в целом лучше SGD: в D–E различаются и оптимизатор, и learning rate; проверено только по два seed.

6. Воспроизводимость

main.py создаёт все 12 историй метрик, нормы градиентов, сравнительные графики, summary.json и этот отчёт. Параметры данных, разбиения, инициализации, оптимизации и seed закреплены в коде. Команды запуска и версии библиотек приведены в README.md и requirements.txt.